

基于自适应粒子群算法求解单目标任务问题研究

摘要

与标准粒子群优化 (Canonical Particle Swarm Optimization Algorithm, PSO) 算法相比, 自适应粒子群优化 (Adaptive Particle Swarm Optimization Algorithm, APSO) 算法具有更高的搜索效率, 更快的收敛速度, 更优的全局搜索能力。APSO主要包括两个步骤: 通过评估种群分布和粒子个体适应值(*fitness*), 确定当前种群处于某种进化状态, 包括勘探、开发、收敛和迁移; 实现惯性权重、加速度系数的自动控制, 实时更新进化参数。当进化状态被归类为收敛状态时, APSO通过精英学习策略得到更精确的解, 相反, 迁移状态通过增加全局最优粒子 ($Gbest_i$) 的加速度系数, 帮助种群跳出局部最优困境。APSO已分别在CEC2017数据集的10D、30D、50D和100D维度上进行实验测试, 并与标准PSO比对。实验结果表明APSO 在收敛速度、全局最优性、解的准确性和算法可靠性方面均显著优于PSO。

关键词: 自适应粒子群优化算法; 粒子群优化算法; 演化计算

1 引言

粒子群优化算法 (Particle Swarm Optimization, PSO) 以其实现简便、易于理解和高效等特性, 在解决现实世界中的多种复杂优化问题方面已获得广泛应用 [4] - [3]。这些应用涵盖了工程设计优化、机器学习参数调优、路径规划、生物信息学等多个领域, 充分展示了PSO在处理连续和离散优化问题上的广泛适用性和卓越性能。

然而, 尽管PSO在许多应用中表现出色, 它仍然存在一些固有的局限性。与其他进化计算方法类似, PSO基于种群的迭代优化, 其核心思想是通过模拟鸟群觅食行为来寻找搜索空间中的最优解 [8]。这种基于种群的特性使得PSO在搜索过程中能够并行探索多个解空间区域, 从而提高了全局搜索能力。然而, 在处理某些复杂的优化问题, 尤其是多模态问题时, 标准PSO (Canonical Particle Swarm Optimization Algorithm, PSO) 易陷入局部最优困境, 且难以摆脱局部最优解的束缚, 导致算法最终收敛于次优解。此外, PSO在某些情况下的收敛速度较慢, 尤其是在高维度和复杂约束条件下, 进一步限制了其应用范围和效率。这些弱点在一定程度上制约了PSO算法在更广泛、更复杂的实际问题中的推广和应用 [7]。

近年来, 提升PSO的收敛速度以及增强其摆脱局部最优困境的能力, 成为该领域内最重要且具有吸引力的两个主要目标。为此, 研究人员提出了许多改进PSO, 这些改进算法的创新点主要集中在算法结构的设计优化、搜索策略调整以及动态自适应参数控制等方面 [5]、[9]、[8]、[1]。例如, 一些研究通过引入自适应惯性权重和加速度系数, 动态调整粒子的搜

索步伐，从而在不同的搜索阶段实现平衡探索与开发的效果；另一些研究则通过结合局部搜索算子或全局优化策略，增强算法的全局搜索能力，避免过早收敛于局部最优解。

然而，尽管已有众多研究致力于提升PSO的性能，但迄今为止，如何同时实现算法加速收敛和有效规避局部最优解的问题，仍然是一个难以克服的挑战。例如，[1]中提出的综合学习粒子群优化（Comprehensive Learning PSO, CLPSO）算法主要侧重于通过增强全局搜索能力来避免局部最优，但在某些情况下其收敛速度相对较慢，未能充分解决优化效率的问题。为克服这些局限性，复现论文提出了一种自适应粒子群优化（Adaptive Particle Swarm Optimization, APSO）算法，该算法通过开发系统参数适应方案和精英学习策略（Elite Learning Strategy, ELS），在保证搜索效率的同时，有效提升了算法的全局搜索能力。

2 相关工作

2.1 标准PSO

在标准PSO以及大多数改进PSO算法中，适应值（*fitness*）被视作单个粒子个体进化结果的评判标准。将适应值优异的粒子选做学习对象是目前惯用的粒子种群优化策略。在简单的单模态问题中，基于适应值的学习对象选择策略可以提供更快的收敛速度，但在复杂的多模态问题中，它可能会导致粒子受困于局部最优解。标准粒子群算法速度更新公式和位置更新公式分别见公式（1）和公式（2）：

$$v_{i,j} = \omega v_{i,j} + c_1 r_1 (pb_{i,j} - v_{i,j}) + c_2 r_2 (gb_{i,j} - v_{i,j}) \quad (1)$$

$$x_{i,j} = x_{i,j} + v_{i,j} \quad (2)$$

其中 w 代表先前的速度惯性权重； c_1 和 c_2 是两个加速度系数； $r_{1,j}$ 和 $r_{2,j}$ 是两个随机数并均匀分布在区间 $[0, 1]$ 上。

基于以上讨论，PSO 可概括为算法 1。

Algorithm 1 标准PSO算法(Canonical Particle Swarm Optimization, PSO).

Input: :粒子个数 N , 问题维度 P , 求解方程 F , 最大迭代次数 gen ;

- 1: 初始化 X, V ; 初始化 $Pbest, Gbest$;
- 2: **while** $fitness$ 未达到最优 or 未达到最大迭代次数 gen **do**
- 3: 更新粒子速度 V (Eq. (1));
- 4: 计算粒子位置 X (Eq. (2));
- 5: 个体最优 $[i] = Pbest[i]$;
- 6: 全局最优 $= Gbest$;
- 7: **end while**

Output: : 全局最优 $Gbest$;

2.2 最新改进PSO算法

鉴于其有效性和简单的概念，PSO 已成为一种流行的优化算法，并被广泛应用于解决实际问题。因此，对该算法的理论研究和性能改进变得非常重要。Clerc 和 Kennedy [1]、Trelea [10]、Yasuda 等人 [12]、Kadirkamanathan 等人 [6]以及 van den Bergh 和 Engelbrecht [11]等人发表了对算法的收敛性分析和稳定性的研究。同时，关于PSO性能改进的研究也有很多文献，包括参数研究、与辅助运算的结合以及相关的拓扑结构 [4]、[7]、[3]。

此外，有作者 [?]还提出将模糊自适应参数 ω 用于调节速度惯性的影响，而 [2]则尝试将 ω 设为由 $0.5 + \text{random}(0, 1)/2$ 得到的随机数值，用于动态系统优化。由于这种随机 ω 的期望值为 0.75，因此它与Clerc的约束因子(为分析收敛行为引入) [1]具有相似的设计思路。

3 方法复现

3.1 划分PSO种群拓扑结构

在自适应粒子群算法(Adaptive Particle Swarm Optimization Algorithm, APSO)的初始优化阶段，作者首先分析了PSO的迭代过程中种群的分布情况，并将其大致划分为三种结构(四种情况)，如图 1, 图 2, 图 3所示，分别指勘探阶段、开发阶段(收敛阶段)、迁移阶段。




图 1. 勘探拓扑结构




图 2. 开发拓扑结构




图 3. 迁移拓扑结构

进化迭代过程中，种群分布结构的划分依据是公式（3）和公式（4）：

$$d_i = \frac{1}{N-1} \sum_{\substack{j=1 \\ j \neq i}}^N \sqrt{\sum_{k=1}^D (x_{ki} - x_{kj})^2} \quad (3)$$

其中，N 和 D 分别为群体规模和粒子个体维数。

$$f = \frac{dg - d_{\min}}{d_{\max} - d_{\min}} \in [0, 1] \quad (4)$$

进化系数 f 数值作为模糊控制系统的重要输入参数，其不同数值控制着APSO对当前拓扑结构的划分判断，详细请参考论文中相关部分的具体描述。

3.2 模糊控制自适应参数

在划分了迭代过程中的种群分布结构后，原论文作者进一步将模糊控制理论应用于进化参数的自适应调整，即实现对 w 、 c_1 和 c_2 的模糊输出控制。如图 4所示，S1、S2、S3和S4分别指收敛阶段、开发阶段、勘探阶段、迁移阶段。




图 4. 四种种群进化结构的模糊隶属度函数

依据进化系数 f ，模糊控制系统将得到与 f 相对应的隶属度计算结果，并依据划分得到的模糊区间以及公式（5）和公式（6），计算或对自适应参数 w 、 c_1 和 c_2 施加约束。

$$\omega(f) = \frac{1}{1 + 1.5e^{-2.6f}} \in [0.4, 0.9] \quad \forall f \in [0, 1] \quad (5)$$

$$c_i = \frac{c_i}{c_1 + c_2} \cdot 4.0, \quad i = 1, 2 \quad (6)$$

最终，将计算出的自适应参数运用于标准PSO中的种群速度、位置迭代过程中。至此，APSO的完整框架设计与创新点介绍完毕。

4 复现细节

4.1 与已有开源代码对比

本次复现工作没有参考任何相关源代码，本次工作完全基于标准PSO框架与论文改进策略设计并编写，在此明确申明。本次复现工作基本实现了APSO中绝大多数创新策略，读者可以下载该代码，并进一步用于自己的科研工作。

4.2 对比实验设置

本研究将APSO在CEC2017基准函数（10维、30维、50维、100维）上进行了实验测试，并将标准PSO算法作为对比算法，分别记录了运行30次的最优解平均值和最优解方差的结果。

5 实验结果分析

		PSO(10D)	APSO(10D)	PSO(30D)	APSO(30D)	PSO(50D)	APSO(50D)
F_1	$\frac{Mean}{S.D.}$	3.130E+03(2) 2.260E+03	2.506E+03(1) 2.021E+03	1.034E+08(2) 3.250E+08	2.537E+03(1) 2.456E+03	3.610E+07(2) 2.410E+07	2.932E+05(1) 4.927E+05
F_2	$\frac{Mean}{S.D.}$	9.287E-14(2) 5.254E-13	0.000E+00(1) 0.000E+00	4.544E+16(2) 7.070E+16	5.072E+15(1) 1.359E+16	1.430E+49(2) 2.820E+49	2.800E+45(1) 6.831E+45
F_3	$\frac{Mean}{S.D.}$	7.330E-11(2) 2.200E-10	0.000E+00(1) 0.000E+00	1.058E+03(1) 5.380E+02	6.322E+03(2) 3.066E+03	7.830E+04(2) 1.020E+04	7.345E+04(1) 1.075E+04
F_4	$\frac{Mean}{S.D.}$	4.840E+00(2) 1.540E+00	3.076E+00(1) 1.774E+00	9.998E+01(2) 2.394E+01	6.696E+01(1) 3.348E+01	2.070E+02(2) 5.360E+01	1.969E+02(1) 4.007E+01
F_5	$\frac{Mean}{S.D.}$	1.090E+01(1) 3.600E+00	3.981E+00(2) 2.350E+00	7.165E+01(2) 1.830E+01	5.569E+01(1) 1.350E+01	1.450E+02(1) 1.990E+01	1.523E+02(2) 2.710E+01
F_6	$\frac{Mean}{S.D.}$	5.680E-14(2) 5.990E-14	0.000E+00(1) 0.000E+00	2.365E-01(2) 1.800E-01	2.009E-08(1) 3.094E-08	3.980E+00(2) 1.920E+00	7.112E-01(1) 1.112E+00
F_7	$\frac{Mean}{S.D.}$	1.590E+01(2) 7.020E+00	1.405E+01(1) 1.719E+00	1.176E+02(2) 2.196E+01	9.930E+01(1) 2.092E+01	3.230E+02(2) 4.160E+01	2.670E+02(1) 5.324E+01
F_8	$\frac{Mean}{S.D.}$	1.100E+01(2) 4.930E+00	5.472E+00(1) 1.774E+00	7.356E+01(2) 1.460E+01	6.526E+01(1) 1.893E+01	1.850E+02(2) 3.040E+01	1.399E+02(1) 2.865E+01
F_9	$\frac{Mean}{S.D.}$	3.400E-12(2) 1.070E-11	0.000E+00(1) 0.000E+00	2.795E+02(2) 3.050E+02	7.540E+01(1) 7.454E+01	3.310E+03(1) 8.960E+02	3.314E+03(2) 2.267E+03
F_{10}	$\frac{Mean}{S.D.}$	2.970E+02(2) 2.300E+02	1.050E+02(1) 6.350E+01	3.050E+03(2) 1.070E+03	2.245E+03(1) 6.481E+02	8.030E+03(2) 9.950E+02	5.201E+03(1) 2.345E+03
F_{11}	$\frac{Mean}{S.D.}$	4.890E+00(2) 2.490E+00	3.080E+00(1) 1.420E+00	9.600E+01(2) 3.100E+01	5.226E+01(1) 2.682E+01	2.290E+02(2) 9.190E+01	1.320E+02(1) 6.687E+01
F_{12}	$\frac{Mean}{S.D.}$	1.790E+04(2) 1.900E+04	1.360E+04(1) 1.020E+04	2.395E+06(2) 4.525E+06	2.101E+05(1) 9.701E+04	8.250E+06(2) 3.350E+06	3.979E+06(1) 2.230E+06
F_{13}	$\frac{Mean}{S.D.}$	8.910E+03(2) 9.330E+03	4.782E+03(1) 4.351E+03	1.316E+04(2) 8.370E+03	6.824E+03(1) 5.319E+03	7.100E+03(2) 9.800E+03	2.649E+03(1) 2.295E+03
F_{14}	$\frac{Mean}{S.D.}$	1.860E+01(2) 1.720E+01	3.338E+00(1) 2.301E+00	1.688E+04(2) 1.700E+04	9.068E+03(1) 6.744E+03	2.340E+05(2) 3.200E+04	7.393E+04(1) 5.846E+04
F_{15}	$\frac{Mean}{S.D.}$	1.920E+01(2) 1.820E+01	2.281E+00(1) 1.749E+00	1.077E+04(2) 1.270E+04	6.621E+03(1) 7.268E+03	9.890E+03(2) 8.520E+03	6.670E+03(1) 7.445E+03

图 5. F_1 到 F_{15} 实验结果

在10维、30维问题上，大多数函数优化问题的求解结果都比较接近最优值，说明两算法在低维度优化时都表现较好。具体来说，在10维问题上，标准PSO表现最优，这反映了基于*Gbest*的引导有助于种群在低维问题上快速求解精准的最优解;在30维问题上，虽然标准PSO在某些问题上取得了最优结果，但APSO在最优结果数量上占更大比例，尤其是在混合函数与复杂函数等复杂多模态函数问题上。

		PSO(10D)	APSO(10D)	PSO(30D)	APSO(30D)	PSO(50D)	APSO(50D)
F_{16}	$\frac{Mean}{S.D.}$	1.860E+01(2) 1.670E+01	2.671E-01(1) 2.188E-01	5.210E+02(1) 2.020E+02	7.377E+02(2) 2.286E+02	1.540E+03(1) 3.820E+02	1.601E+03(2) 6.324E+02
F_{17}	$\frac{Mean}{S.D.}$	1.140E+01(2) 1.210E+01	7.762E+00(1) 8.541E+00	2.156E+02(2) 1.260E+02	1.793E+02(1) 1.399E+02	9.960E+02(2) 3.090E+02	8.202E+02(1) 2.410E+02
F_{18}	$\frac{Mean}{S.D.}$	5.470E+03(2) 1.040E+04	2.018E+03(1) 3.624E+03	2.510E+05(2) 2.280E+05	3.874E+05(1) 3.290E+05	1.120E+06(1) 1.800E+06	2.280E+06(2) 1.756E+06
F_{19}	$\frac{Mean}{S.D.}$	5.140E+01(2) 7.560E+01	1.372E+00(1) 8.555E-01	1.527E+04(2) 1.670E+04	9.195E+03(1) 1.060E+04	2.660E+04(2) 1.830E+04	2.144E+04(1) 1.075E+04
F_{20}	$\frac{Mean}{S.D.}$	4.770E+00(2) 8.470E+00	6.854E-01(1) 6.081E-01	1.870E+02(1) 1.230E+02	2.316E+02(2) 1.549E+02	7.020E+02(2) 2.670E+02	6.547E+02(1) 2.807E+02
F_{21}	$\frac{Mean}{S.D.}$	1.160E+02(1) 5.760E+01	1.335E+02(2) 5.357E+01	2.740E+02(2) 1.590E+01	2.600E+02(1) 1.283E+01	3.950E+02(2) 2.250E+01	3.491E+02(1) 2.356E+01
F_{22}	$\frac{Mean}{S.D.}$	1.030E+02(2) 3.320E+00	1.022E+02(1) 6.391E-01	1.010E+03(2) 1.490E+03	3.922E+02(1) 9.226E+02	1.020E+04(2) 2.200E+03	7.433E+03(1) 3.013E+03
F_{23}	$\frac{Mean}{S.D.}$	3.180E+02(2) 7.540E+00	3.106E+02(1) 3.742E+00	4.306E+02(2) 1.700E+01	4.214E+02(1) 2.798E+01	6.360E+02(2) 3.380E+01	5.941E+02(1) 2.960E+01
F_{24}	$\frac{Mean}{S.D.}$	2.250E+02(1) 1.320E+02	2.991E+02(2) 1.058E+02	5.166E+02(2) 2.640E+01	5.113E+02(1) 3.230E+01	7.230E+02(2) 4.350E+01	6.724E+02(1) 4.505E+01
F_{25}	$\frac{Mean}{S.D.}$	4.370E+02(2) 1.950E+01	4.227E+02(1) 2.425E+01	3.875E+02(2) 1.730E+00	3.873E+02(1) 2.054E+00	6.280E+02(2) 6.870E+01	5.965E+02(1) 3.953E+01
F_{26}	$\frac{Mean}{S.D.}$	3.320E+02(2) 6.640E+01	2.765E+02(1) 9.871E+01	1.920E+03(2) 2.190E+02	1.857E+03(1) 3.130E+02	3.500E+03(2) 4.770E+02	2.919E+03(1) 4.484E+02
F_{27}	$\frac{Mean}{S.D.}$	4.020E+02(2) 2.760E+01	3.947E+02(1) 3.563E+00	5.135E+02(1) 5.480E+00	5.226E+02(2) 1.120E+01	6.560E+02(2) 8.600E+01	6.466E+02(1) 9.819E+01
F_{28}	$\frac{Mean}{S.D.}$	4.470E+02(2) 1.130E+02	3.000E+02(1) 0.000E+00	4.479E+02(2) 2.470E+01	4.119E+02(1) 1.924E+01	5.760E+02(2) 4.170E+01	5.749E+02(1) 3.011E+01
F_{29}	$\frac{Mean}{S.D.}$	2.530E+02(1) 2.240E+01	2.481E+02(2) 8.632E+00	6.455E+02(2) 1.600E+02	6.289E+02(1) 1.933E+02	1.050E+03(2) 2.090E+02	8.874E+02(1) 2.056E+02
F_{30}	$\frac{Mean}{S.D.}$	8.590E+04(2) 2.570E+05	3.325E+03(1) 2.681E+03	1.020E+04(2) 1.000E+04	6.482E+03(1) 2.775E+03	1.170E+06(1) 4.590E+05	8.455E+06(2) 1.650E+05

图 6. F_{16} 到 F_{30} 实验结果

在50维的高维问题上，两算法的最终优化结果相较于低维问题显著提高，这反映了高维优化问题的搜索难度随着维度的上升有着明显的提升。随着维度的增加，在50维问题上，标准PSO的求解结果偏高，仅在少部分简单函数上表现出色，整体来看，APSO在大多数问题上更有效性。对比中低维函数优化问题的实验结果，APSO的优势在复杂低维问题以及绝大多数高维问题上更为明显，这说明通过模糊逻辑控制的自适应粒子个体的全局搜索能力更优，可以有效应对复杂高维问题。

6 总结与展望

自适应粒子群优化（APSO）算法提升了标准PSO的算法性能，具有更高的搜索效率，更快的收敛速度，更优的全局搜索能力。APSO已在CEC2017数据集的10维、30维、50维度上问题上完成实验测试，并与标准PSO比对。实验结果证实了APSO在CEC2017数据集中的复杂高维问题上具有有效性。在本次算法复现工作的基础之上，还可以通过简化算法内部的函数表达式来提高APSO的可解释性。在尝试降低当前算法计算量的同时，可以进一步研究模糊逻辑控制理论对应的种群拓扑结构的种类划分，提升自适应参数计算系统的求解性能。

参考文献

- [1] M. Clerc and J. Kennedy. The particle swarm-explosion, stability and convergence in a multidimensional complex space. *IEEE Trans. Evol. Comput.*, 6(1):58–73, Feb. 2002.
- [2] R. C. Eberhart and Y. Shi. Tracking and optimizing dynamic systems with particle swarms. In *Proc. IEEE Congr. Evol. Comput.*, pages 94–97, Seoul, Korea, 2001.
- [3] R. C. Eberhart and Y. Shi. Guest editorial. *IEEE Trans. Evol. Comput.*, 8(3):201–203, Jun. 2004.
- [4] R. C. Eberhart and Y. H. Shi. Particle swarm optimization: Developments, applications and resources. In *Proc. IEEE Congr. Evol. Comput.*, pages 81–86, Seoul, Korea, 2001.
- [5] S.-Y. Ho, H.-S. Lin, W.-H. Liauh, and S.-J. Ho. Opso: Orthogonal particle swarm optimization and its application to task assignment problems. *IEEE Trans. Syst., Man, Cybern. A, Syst., Humans*, 38(2):288–298, Mar. 2008.
- [6] V. Kadirkamanathan, K. Selvarajah, and P. J. Fleming. Stability analysis of the particle dynamics in particle swarm optimizer. *IEEE Trans. Evol. Comput.*, 10(3):245–255, Jun. 2006.
- [7] X. D. Li and A. P. Engelbrecht. Particle swarm optimization: An introduction and its recent developments. In *Proc. Genetic Evol. Comput. Conf.*, pages 3391–3414, 2007.
- [8] J. J. Liang, A. K. Qin, P. N. Suganthan, and S. Baskar. Comprehensive learning particle swarm optimizer for global optimization of multimodal functions. *IEEE Trans. Evol. Comput.*, 10(3):281–295, Jun. 2006.

- [9] B. Liu, L. Wang, and Y. H. Jin. An effective pso-based memetic algorithm for flow shop scheduling. *IEEE Trans. Syst., Man, Cybern. B, Cybern.*, 37(1):18–27, Feb. 2007.
- [10] I. C. Trelea. The particle swarm optimization algorithm: Convergence analysis and parameter selection. *Inf. Process. Lett.*, 85(6):317–325, Mar. 2003.
- [11] F. van den Bergh and A. P. Engelbrecht. A study of particle optimization particle trajectories. *Inf. Sci.*, 176(8):937–971, Apr. 2006.
- [12] K. Yasuda, A. Ide, and N. Iwasaki. Stability analysis of particle swarm optimization. In *Proc. 5th Metaheuristics Int. Conf.*, pages 341–346, 2003.